

Kalmanov filter in sledenje z delci

4. naloga pri predmetu Napredne metode računalniškega vida

Ivan Antešić¹

Fakulteta za računalništvo in informatiko, Univerza v Ljubljani, Večna pot 113,
Slovenija

`ia6382@student.uni-lj.si`

Keywords: Računalniški vid · Kalman · Sledilnik · Delci · Filter.

1 Uvod

V okviru četrte naloge smo implementirali različne modele gibanj za Kalmanov filter in razvili preprost sledilnik z delci. Algoritma sta bila analizirana na testnih sekvencah slik vot2014 (<http://box.vicos.si/vot/vot2014.zip>) z uporabo ogrodja Tracking Evaluation Toolkit (<https://github.com/alanlukezic/tracking-toolkit-lite>).

1.1 Kalmanov filter

Kalmanov filter uporablja principe sledenja z rekurzivnimi Bayesovimi filtri [3] (za določitev stanja tarče uporablja Bayesove principe verjetosti) in po spodnji formuli zglati morebitno šumne meritve:

$$p(x_k | y_{1:k}) \propto p(y_k | x_k) \int p(x_k | x_{k-1}) p(x_{k-1} | y_{1:k-1}) dx_{k-1}$$

Iz prejšnjega stanja (prior) z modelom gibanja predvidi naslednje stanje (posterior) in pri tem upošteva meritev. V naslednji iteraciji postane posterior prejšnje stanje. Kalmanov filter si lahko predstavljamo kot zelo dobro uteženo povprečje meritve in napovedi modela.

Kalmanov filter predpostavi, da so vsi členi predstavljeni z funkcije Gaussove porazdelitve in s tem upošteva negotovost stanj tarče. Iz formule je razvidno, da ima model gibanja vpliv na končno vrednost stanja. Stanje smo predstavili z vektorjem x in y komponent:

- položaja
- hitrosti (časovnim odvodom položaja)
- pospeška (časovnim odvodom hitrosti)
- pri modelu NCA še dodatno z sunkom (časovnim odvodom pospeška)

RW Pri modelu naključne hoje je hitrost definirana le z šumom, pospeška in sunka ne upoštevamo. Model je primeren za opis hitrih nenadnih in nepričakovanih sprememb.

NCV Model skoraj konstantne hitrosti opisuje gibanje, ki ima konstanto hitrost in pospešek definiran z šumom. Primeren za objekte, ki se premikajo brez pospeška (npr. avto, ki vozi z isto hitrostjo)

NCA Model skoraj konstantnega pospeška je predstavljen z konstantno hitrostjo in pospeškom, nenadni sunki pa so definirani z šumom. Primerno za objekte, ki postopoma pospešujejo ali zavirajo svoje gibanje (npr. vzlet letala).

1.2 Sledenje z delci

Kalmanov filter predpostavi da je verjetnostna funkcija Gaussove oblike. Velikokrat to ne drži, lahko dobimo težjo funkcijo z večimi vrhi. V teh primerih posterior opišemo kot model večih Gaussov (mixture model). Ker ne vemo vnaprej koliko Gaussovih funkcij potrebujemo, iz verjetnostne funkcije vzorčimo veliko Diracovih funkcij. Intergriranje nadomestimo z Monte Carlo integracijo ter z računanjem uteži vzorcev dosežemo enako (ampak lažje) vzorčenje težkih funkcij. Tako rekurzivni Bayesov filter nadomestimo z filtrom delcev, ki ga lahko uporabimo za sledenje [3].

Delec je vzorec, ki predstavlja vizuelni model in vsebuje utež, katere vrednost je odvisna od podobnosti vizuelnega modela predloge (angl. template). Tarčo predstavimo z N delci. V vsakem koraku sledenja vzorčimo delce glede na njihove uteži, premaknemo delce z modelom gibanja in na novo izračunamo uteži.

V implementaciji smo za vizuelni model izbrali barvni histogram, saj je neodvisen od transformacij oblike tarče. Podobnost med delci in predlogo smo računali z Hellingerjevo razdaljo, ki smo jo z eksponentno funkcijo pretvorili v verjetnost. Vizuelni model predloge se skozi čas postopoma prilagaja z naslednjo formulo, kjer parameter alfa določa hitrost posodabljanja, H pa je vizuelni model histograma: $H_{novi} = (1 - alfa) * H_{stari} + alfa * H_{trenutni}$

2 Testiranje

2.1 Kalmanov filter

Spodaj so predstavljeni rezultati testiranja vpliva različnih modelov gibanja in parametrov na Kalmanov filter. Model gibanja je implementiran z matriko sistema (F_i) in kovarianco sistema (Q). Na kovarianco sistema vpliva parameter q , ki določa kako močno bo razpršen šum, ki se uporablja v modelu.

Polega tega je potrebno ustrezno nastaviti tudi parameter r , ki podobno kot q vpliva na kovarianco meritve (matrika R), ki meritvam dodam šum. Za časovni korak T smo predpostavili, da ima vedno vrednost 1.

Pri vrednosti parametra $q = r = 1$ je vpliv šuma majhen tako na meritve kot na model gibanja. Na sliki 1 lahko vidimo vpliv modela gibanja na Kalmanov filter. Razvidno je da model NCV malo zaostaja za meritvami, saj ne upošteva dovolj pospeška (krivulja meritev se postopoma zmanjšuje).




Fig. 1. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=1$, $r=1$.

RW model upošteva le položaj in zato le približno sledi krivulji meritev. NCA na začetku sledi podobno kot NCV, kasneje pa se zaradi upoštevanja pospeška lepše prilagodi krivulji meritev. Enak graf dobimo za vse vrednosti pri katerih sta q in r enaka - Kalmanov filter za napovedovanje enakovredno upošteva meritve in model gibanja, saj je varianca (posledično šum) pri obeh ista (slika 2).




Fig. 2. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=100$, $r=100$.

Če r pustimo majnen, povečamo pa vrednost parametra q in s tem šum modela gibanja opazimo (na sliki 3), da se krivulje modelov obnašajo enako kot prej le da se sedaj bolj prilegajo krivulji meritev. Če efekt pojačamo in vrednost q močno povečamo, lahko na sliki 4 vidimo, da se kalmanove krivulje popolnoma ujemajo z meritvami - vpliv modela je izničen. Takšno delovanje je posledica velikega šuma modela, zaradi katerega pri filtriranju upoštevamo le meritve - vrednosti modela se preveč razlikujejo od meritev, da bi jih še upoštevali.

Obratno delovanje lahko opazimo na sliki 5 in 6. Vrednosti meritev so preveč šumne v primerjavi z napovedmi, zato se upošteva bolj model gibanja. NCA in NCV še vedno približno ohranita obliko spirale (NCV bolje kot NCA saj pospešek NCA pokvari obliko), medtem ko se model RW popolnoma izrodi, ker je večinsko odvisen le od položaja.

Delovanje smo testirali tudi na dveh dodatnih krivuljah.

Pri sinusni krivulji z polovico številom točk ($N = 20$) je delovanje podobno, le da se kalmanova krivulja bolj prilega meritvam, saj v primerjavi z spiralo, ne




Fig. 3. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=5$, $r=1$.




Fig. 4. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=100$, $r=1$.

spreminja konstantno smeri (slika 7). Na sliki 8 lahko vidimo upoštevanje samo dinamičnega modela. NCV zgladi meritve v bolj položno a manjšo krivuljo, RW preveč zgladi in se izroji, NCA pa se približno prilagodi meritvam.

Pri testiranju na gaussovi krivulji, z 20 točkami, lahko lepo vidimo vpliv modelov gibanja (slika 9). Model RW zgladi meritve krivulje in se ustavi pravočasno, ko ta pada na desni strani. NCV zaradi upoštevanja hitrosti nadaljuje glajenje čez spodnjo mejo krivulje preden se vrne v ravnovesno lego. Model NCA zaradi upoštevanja pospeška, nadaljuje glajenje čez spodnjo mejo ter nato preveč naraste preden doseže ravnovesno lego (naredi nekakšno nihanje).

2.2 Sledenje z delci

Na delovanje sledilnika vpliva predvsem število vzorcev N , izbrani model gibanja, parameter q , ki vpliva na velikost šuma modela.

Varianca verjetnosti sigma Na računanje uteži vzorcev vpliva varianca sigma; manjša je sigma, bolj smo kritični pri preverjanju podobnosti in oddaljenim delcem hitreje pade vrednost uteži. Posledica je, da zunaj ležeči delci izginejo v enem ali dveh zaporednih slikah. Z eksperimentiranjem smo določili, da sledilnik dobro deluje pri vrednosti sigma je 0,5.




Fig. 5. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=1$, $r=5$.




Fig. 6. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=1$, $r=100$.

Razpršenost q Velikost parametra q preko modela gibanja vpliva na razpršenost delcev. Razpršenost močno vpliva na delovanje sledilnika, kar je vidno v sekvencah kjer pride do nenadnih hitrih premikov. Na sliki 10 je prikazan takšen primer. Ker je q dovolj velik so delci zadostno razpršeni, da ob hitrem premiku žoge nekateri padejo na območje kjer se tarča trenutno nahaja in se jim posledično močno poveča utež. Kljub temu, da je večina delcev zunaj območja tarče se zaradi njihove majhne uteži povprečna pozicija tarče izračuna pravilno in uspemo slediti žogi.

Razpršenost pozitivno vpliva tudi v primernih delne pokritosti tarče, kjer zaradi delcev, ki še ležijo na nepokriti tarči ohranimo sledenje.

Prevelik q lahko povzroči prekomerno razpršenost, zaradi česar lahko izgubimo tarčo. Na sliki 11 lahko opazimo težavo, ko se tarči približa podoben objekt. Oddaljenim delcem, ki padejo na objekt se poveča utež in v naslednjem koraku se bo lahko v tisti regiji vzorčilo več delcev. Postopoma lahko tako izgubimo tarčo in se osredotočimo na napačni objekt.

V implementaciji smo q določili glede na velikost tarče in celotne slike. Če je tarča obsega velik del slike lahko pričakujemo, da se bo med premaknila za večjo razdaljo, ker je bližje kameri, kot manjša tarča. Pričakovani premik smo izračunali z naslednjo formulo: $\frac{(\frac{sirinaSlike}{sirinaTarce}/3) + (\frac{visinaSlike}{visinaTarce}/3)}{2}$ to pa smo uporabili za racunanje okvirnega q v formuli $3/4 * pricakovaniPremik^2$.




Fig. 7. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=1$, $r=1$.




Fig. 8. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=1$, $r=100$.

število delcev N Število delcev N vpliva na hitrost sledilnika in njegovo uspešnost. Z eksperimentiranjem smo ugotovili, da število delcev lahko zmanjšamo, če povečamo njihovo razpršenost z q . Pri velikemu številu delcev in manjšemu q bodo lahko nekateri delci še vedno izbrani malce dlje od tarče. Če je delcev manj moramo zato povečati q , da ujamemo tarčo pri večjih premikih.

Pri testiranju na skevenci "ball" je sledilnik z 100 delci ujel žogo pri velikem premiku z minimalno razpršenostjo $q = 7$. Ko smo število delcev razpolovili ($N = 50$) je bila potrebna vrednost parametra $q = 15$ (tarčo smo včasih ujeli tudi pri $q = 11$, vendar je bila pokritost zelo majhna).

Na sliki 12 in tabeli 1 lahko razberemo delovanje sledilnika z številom delcev 50, 75 in 100. Kot pričakovano se povprečna hitrost sledilnika (v sličicah na sekundo - fps) se zmanjšuje z več delci:

- 61 fps za 25 delcev
- 28 fps za 50 delcev
- 19 fps za 75 delcev
- 15 fps za 100 delcev

Časovne meritve so bile izmerjene za sekvenco "woman".

Kot kompromis med hitrostjo in zmogljivostjo sledilnika smo izbrali število delcev $N = 50$, saj pri večjih delcih hitrost močno upade, zmogljivost pa se ne poveča veliko.

Sequence	particleN25		particleN50		particleN75		particle100	
	Overlap	Failures	Overlap	Failures	Overlap	Failures	Overlap	Failures
ball	0.52	2	0.60	0	0.62	0	0.67	1
basketball	0.51	7	0.60	2	0.62	1	0.64	1
bicycle	0.50	10	0.46	9	0.48	6	0.46	4
bolt	0.47	23	0.43	18	0.45	23	0.46	19
car	0.39	2	0.37	1	0.38	0	0.41	0
david	0.42	5	0.53	1	0.58	1	0.60	1
diving	0.47	4	0.40	4	0.37	4	0.30	3
drunk	0.37	3	0.47	2	0.43	2	0.42	2
fernando	0.32	4	0.41	2	0.38	2	0.28	1
fish1	0.44	12	0.42	8	0.39	8	0.38	6
fish2	0.41	11	0.43	8	0.39	8	0.39	7
gymnastics	0.37	2	0.49	0	0.52	2	0.51	1
hand1	0.37	5	0.49	1	0.45	3	0.48	0
hand2	0.39	6	0.42	6	0.42	6	0.41	7
jogging	0.54	3	0.54	3	0.59	2	0.53	2
motocross	0.46	3	0.45	4	0.48	4	0.48	4
polarbear	0.51	3	0.62	1	0.60	1	0.64	0
skating	0.46	12	0.45	11	0.46	11	0.49	11
sphere	0.46	1	0.52	1	0.54	1	0.50	1
sunshade	0.42	4	0.54	0	0.50	1	0.58	1
surfing	0.47	9	0.50	4	0.48	3	0.44	3
torus	0.47	3	0.49	2	0.57	1	0.55	1
trellis	0.43	8	0.46	3	0.49	3	0.48	1
tunnel	0.40	23	0.38	19	0.36	17	0.41	15
woman	0.46	13	0.49	8	0.52	6	0.56	5
Average	0.44	7.12	0.48	4.72	0.48	4.64	0.48	3.88

Table 1. Rezultati testiranja sledilnikov z različnim številom delcev (25, 50, 75 in 100) na testnih sekvencah vot2014.




Fig. 9. Glajenje meritev (rdeča krivulja) z Kalmanovim filtrom (modra krivulja) pri modelih gibanja RW, NCV in NCA ter parametrom $q=1$, $r=1$.




Fig. 10. Lokalizacija tarče z sledilnikom na sekvenci "ball". Parameter $q=14$, $N=50$. Zeleni delci so prikazani različnih velikosti glede na vrednost njihove uteži.

Model gibanja Do sedaj smo za model gibanja sledilnika uporabljali model skoraj konstantne hitrosti NCV. Sledilnik smo testirali še z uporabo modela naključne hoje (RW) in modela skoraj konstantnega pospeška (NCA).

Na sliki 13 in tabeli 2 je prikazano delovanje sledilnika, pri teh modelih gibanja. NCA v vseh primerih deluje slabše kot preostala modela. Pokritost je večja le zaradi večjega števila reinicializiranj po odpovedi sledilnika.

Model RW ima presenteljivo najmanj odpovedi in le zanemarljivo manjše pokritje kot NCV. Menimo, da je razlog za takšno delovanje manjša razpršenost pri modelu RW, ki upošteva le položaj, ne pa tudi hitrosti in pospeška kot druga modela (slika 14 in 15). Posledično se delci med dvema zaporednima slikama ne premikajo tako burno. Podobno lahko pojasnimo razliko o delovanju med NCV in NCA modelom. NCV deluje bolje kot RW pri sekvencah hitrih premikov - npr. "ball".

Sequence	particleRW		particleNCV		particleNCA	
	Overlap	Failures	Overlap	Failures	Overlap	Failures
ball	0.53	3	0.60	0	0.56	26
basketball	0.57	1	0.60	2	0.52	40
bicycle	0.44	0	0.46	9	0.47	21
bolt	0.56	3	0.43	18	0.52	31
car	0.39	0	0.37	1	0.53	13
david	0.59	0	0.53	1	0.54	27
diving	0.35	0	0.40	4	0.46	10
drunk	0.26	1	0.47	2	0.55	34
fernando	0.37	2	0.41	2	0.40	8
fish1	0.35	9	0.42	8	0.46	28
fish2	0.23	3	0.43	8	0.51	22
gymnastics	0.55	0	0.49	0	0.53	10
hand1	0.35	7	0.49	1	0.51	12
hand2	0.37	9	0.42	6	0.48	13
jogging	0.70	2	0.54	3	0.55	18
motocross	0.34	4	0.45	4	0.45	8
polarbear	0.67	0	0.62	1	0.54	17
skating	0.44	1	0.45	11	0.53	26
sphere	0.32	2	0.52	1	0.52	6
sunshade	0.51	7	0.54	0	0.45	10
surfing	0.63	0	0.50	4	0.49	20
torus	0.38	7	0.49	2	0.46	13
trellis	0.45	2	0.46	3	0.49	27
tunnel	0.42	3	0.38	19	0.45	55
woman	0.60	2	0.49	8	0.53	35
Average	0.46	2.72	0.48	4.72	0.50	21.20

Table 2. Rezultati testiranja sledilnikov z različnimi modeli gibanja (RW, NCV, NCA) na testnih sekvencah vot2014.




Fig. 11. Lokalizacija tarče z sledilnikom na sekvenci "basketball". Parameter $q=40$, $N=50$. Zeleni delci so prikazani različnih velikosti glede na vrednost njihove uteži.

Zaradi te ugotovitve smo se odločili testirati z manjšim q sekvence, pri katerih je RW deloval bolje kot NCV. Sledilnik je deloval bolje, vendar še vedno ne tako dobro kot RW in ni bil dovolj splošen za ostale sekvence.

Barvni prostori Sledilnik smo preizkusili tudi z uporabo različnih barvnih prostorov v katerih smo naredili histogram. Na sliki 16 in tabeli 3 je prikazano delovanje sledilnika v barvnih prostorih RGB, HSV in YCrCb. Pri RGB smo uporabili histogram z 16 koši (angl. bins), pri HSV ter YCrCb pa 8 košev. Izkazalo se je, da sledilnik najbolje deluje v barvnem prostoru RGB.

3 Zaključek

Z ustrezno nastavitvijo parametrov, predvsem števila delcev N in razpršenostjo q lahko dosežemo kompromis in zadovoljivo sledenje. Čeprav je sledilnik zaradi večjega števila delcev počasnejši, kot prejšni deluje bolje in je zmožen slediti hitrim premikom in delnim prekritostim.

Ugotovili smo, da naša implementacija najbolje deluje z modelom RW in v barvnem prostoru RGB. Naš preprost sledilnik bi lahko izboljšali z izboljšanjem vizuelnega modela. Vrednost parametra alfa (ki nadzuruje hitrost posodobitve predloge) bi lahko dinamično prilagajali, odvisno od podobnosti vizuelnega modela tarče in predloge.

Sequence	particleRGB		particleHSV		particleYCbCr	
	Overlap	Failures	Overlap	Failures	Overlap	Failures
ball	0.53	3	0.45	3	0.48	2
basketball	0.57	1	0.55	3	0.39	2
bicycle	0.44	0	0.49	0	0.51	0
bolt	0.56	3	0.58	3	0.60	1
car	0.39	0	0.39	1	0.40	1
david	0.59	0	0.53	0	0.50	2
diving	0.35	0	0.33	0	0.38	0
drunk	0.26	1	0.29	2	0.31	2
fernando	0.37	2	0.36	2	0.35	2
fish1	0.35	9	0.30	11	0.29	10
fish2	0.23	3	0.20	2	0.28	9
gymnastics	0.55	0	0.52	0	0.53	0
hand1	0.35	7	0.23	6	0.29	7
hand2	0.37	9	0.34	13	0.36	13
jogging	0.70	2	0.64	1	0.60	0
motocross	0.34	4	0.32	4	0.30	4
polarbear	0.67	0	0.60	1	0.60	1
skating	0.44	1	0.42	0	0.42	1
sphere	0.32	2	0.24	4	0.39	4
sunshade	0.51	7	0.37	11	0.41	10
surfing	0.63	0	0.69	0	0.55	0
torus	0.38	7	0.33	6	0.38	6
trellis	0.45	2	0.39	4	0.40	3
tunnel	0.42	3	0.35	5	0.36	9
woman	0.60	2	0.58	2	0.56	1
Average	0.46	2.72	0.42	3.36	0.43	3.60

Table 3. Rezultati testiranja sledilnikov z različnimi barvnimi prostori (RGB, HSV, YCbCr) na testnih sekvencah vot2014.




Fig. 12. A-R graf sledilnikov z različnim številom delcev.

Iz ozadja bi lahko pridobili dodatni histogram in z njim ustrezno utežili regije, ki se večinoma nahajajo v ozadju in tako preprečili osredotočanje sledilnika na ozadje tarče [1].

Dodatno bi lahko z optičnim tokom upoštevali smer premika in tako razločili med podobnimi objekti, ki se prekrivajo [2].

Literatura

1. Kristan, M., Pers, J., Perse, M., Kovacic, S., Bon, M.: Multiple interacting targets tracking with application to team sports. In: ISPA 2005. Proceedings of the 4th International Symposium on Image and Signal Processing and Analysis, 2005. pp. 322–327 (Sep 2005). <https://doi.org/10.1109/ISPA.2005.195431>
2. Kristan, M., Pers, J., Kovačič, S., Leonardis, A.: A local-motion-based probabilistic model for visual tracking 1. Pattern Recognition **42**, 2160–2168 (09 2009). <https://doi.org/10.1016/j.patcog.2009.01.002>
3. Prince, S.J.D.: Computer Vision: Models, Learning, and Inference. Cambridge University Press, New York, NY, USA, 1st edn. (2012)




Fig. 13. A-R graf sledilnikov z različnimi modeli gibanja.



Fig. 14. Lokalizacija tarče z sledilnikom na sekvenci "bolt". Parameter $q=41$, $N=50$, uporabljen je model gibanja RW. Zeleni delci so prikazani različnih velikosti glede na vrednost njihove uteži.



Fig. 15. Lokalizacija tarče z sledilnikom na sekvenci "bolt". Parameter $q=41$, $N=50$, uporabljen je model gibanja NCV. Zeleni delci so prikazani različnih velikosti glede na vrednost njihove uteži.




Fig. 16. A-R graf sledilnikov z različnimi barvnimi prostori.